

การทำนายผลความไวต่อยาต้านจุลชีพแบบ S/I/R ด้วยการเรียนรู้ของเครื่องจากข้อมูลจุลชีววิทยาโรงพยาบาลที่ผ่านการควบคุมคุณภาพข้อมูล

Machine Learning Prediction of Antimicrobial Susceptibility Categories (S/I/R) from Data Quality-Controlled Hospital Microbiology Data

จิตติพัฒน์ สนม¹, ฉันทชนก อร่ามรัตน์¹, กิตติกร หาญตระกูล¹, พาสน์ ปราโมกษ์ชน¹,
อลงกต กองมณี¹, และ สมนึก สิ้นธพาน^{1*}

¹สาขาวิทยาการคอมพิวเตอร์ คณะวิทยาศาสตร์ มหาวิทยาลัยแม่โจ้ 50290 ประเทศไทย

* ผู้พิมพ์ประสานงาน: สมนึก สิ้นธปวน อีเมล: somnuk@mju.ac.th

Jittiphat Sanom¹, Chanchanok Aramrat¹, Kittikorn Hantrakul¹, Part Pramokchon¹,
Alongkot Gongmanee¹, and Somnuek Sinthupuan^{1*}

¹Computer Science Department, Faculty of Science, Maejo University

*Corresponding author: somnuk@mju.ac.th

Abstract

Hospital microbiology data are often affected by missing values, duplicate records, inconsistent naming, and heterogeneous coding across information systems, which limit their usability for machine-learning analysis. This study aimed to develop a machine-learning framework for predicting antimicrobial susceptibility categories (S/I/R) from hospital microbiology data after systematic data quality assessment and preprocessing. An end-to-end pipeline was developed, comprising data quality assessment in two dimensions—completeness and consistency—followed by data preprocessing to standardize organism names, specimen types, antibiotic names, and susceptibility-result fields using dictionary mapping, regular expressions, and fuzzy matching. Intrinsic-resistance rules were applied, records that could not be reliably interpreted were flagged as REVIEW and excluded from supervised learning, and repeated isolates were removed using a study-defined first-isolate rule within 30 days to reduce bias from duplicate results. The final model-ready dataset was used to train and compare four tree-based machine-learning models—Decision Tree, Random Forest, XGBoost, and CatBoost—for predicting anti result clean (S/I/R) from

microbiology and patient-context features. To address class imbalance, CTGAN-based augmentation was applied to the training data only. Model performance was evaluated using accuracy, macro precision, macro recall, macro F1-score, and confusion matrices under three experimental settings with gradual feature removal. Random Forest achieved the best performance in all settings, with the highest accuracy of 75.05% and macro F1-score of 0.75 when using organism, antibiotic, specimen, sex, age, and ward features. When organism information was removed, accuracy decreased to 66.33%, and when both organism and antibiotic features were removed, accuracy further decreased to 62.36%. These findings indicate that microbiology data that have undergone systematic data quality control and preprocessing can support reproducible machine-learning prediction of antimicrobial susceptibility categories, and that organism and antibiotic variables contribute most strongly to predictive performance.

Keywords: Data Quality Assessment, Data Preprocessing, Machine Learning, Antimicrobial Susceptibility Testing, S/I/R Prediction, Antimicrobial Resistance, CTGAN, Random Forest

บทคัดย่อ

ข้อมูลผลการทดสอบความไวต่อยาต้านจุลชีพจากระบบสารสนเทศโรงพยาบาลมักมีปัญหาคุณภาพ ข้อมูล เช่น ค่าว่าง ข้อมูลซ้ำ ความไม่สอดคล้องของการตั้งชื่อเชื้อ ยา และสิ่งส่งตรวจ ตลอดจนรูปแบบรหัสข้อมูลที่แตกต่างกันระหว่างระบบ ซึ่งส่งผลกระทบต่อความน่าเชื่อถือของการวิเคราะห์ด้วยการเรียนรู้ของเครื่อง งานวิจัยนี้มีวัตถุประสงค์เพื่อพัฒนากอบการการเรียนรู้ของเครื่องสำหรับทำนายผลความไวต่อยาต้านจุลชีพแบบ S/I/R จากข้อมูลจุลชีววิทยาของโรงพยาบาลที่ผ่านการประเมินและควบคุมคุณภาพข้อมูลอย่างเป็นระบบ โดยพัฒนา pipeline แบบครบวงจรที่ประกอบด้วย การประเมินคุณภาพข้อมูล 2 มิติ ได้แก่ ความครบถ้วนและความสอดคล้อง จากนั้นดำเนินการเตรียมข้อมูลโดยทำมาตรฐานชื่อเชื้อ ชนิดสิ่งส่งตรวจ ชื่อยา และผลความไวต่อยา ด้วย dictionary mapping, regular expressions และ fuzzy matching พร้อมตรวจสอบ intrinsic resistance กำหนด REVIEW สำหรับรายการที่ไม่สามารถตีความได้อย่างน่าเชื่อถือและไม่นำเข้าสู่การเรียนรู้แบบมีผู้สอน รวมทั้งคัดข้อมูลซ้ำด้วย first-isolate rule ภายใน 30 วันเพื่อลดอคติจากผลตรวจซ้ำ ชุดข้อมูลที่ได้รับการเตรียมถูกนำมาใช้ฝึกและเปรียบเทียบโมเดลการเรียนรู้ของเครื่องแบบ tree-based จำนวน 4 โมเดล ได้แก่ Decision Tree, Random Forest, XGBoost และ CatBoost เพื่อ

ทำนายตัวแปร anti_result_clean ซึ่งมี 3 classes คือ S, I และ R โดยใช้ตัวแปรด้านจุลชีววิทยาและข้อมูลบริบทผู้ป่วยเป็นตัวอธิบาย เพื่อแก้ปัญหาความไม่สมดุลของข้อมูล ได้ใช้ CTGAN สร้างข้อมูลสังเคราะห์เฉพาะในชุดฝึกเท่านั้น การประเมินประสิทธิภาพใช้ Accuracy, Macro Precision, Macro Recall, Macro F1-score และ Confusion Matrix ภายใต้การทดลอง 3 กรณีที่ลดจำนวนตัวแปรลงตามลำดับ ผลการทดลองพบว่า Random Forest ให้ผลดีที่สุดในทุกกรณี โดยกรณีที่ใช้ตัวแปรครบได้แก่ ชื่อเชื้อ ชื่อยา สิ่งส่งตรวจ เพศ อายุ และหอผู้ป่วย ให้ความแม่นยำสูงสุด 75.05% และ Macro F1-score เท่ากับ 0.75 เมื่อถอดตัวแปรชื่อเชื้อออก ความแม่นยำลดลงเหลือ 66.33% และเมื่อถอดทั้งชื่อเชื้อและชื่อยาออก ความแม่นยำลดลงต่อเนื่องเป็น 62.36% ผลการศึกษานี้แสดงให้เห็นว่า ข้อมูลจุลชีววิทยาที่ผ่านการควบคุมคุณภาพและการเตรียมข้อมูลอย่างเป็นระบบสามารถนำมาใช้ทำนายผลความไวต่อยาต้านจุลชีพแบบ S/I/R ได้อย่างทำซ้ำได้ และตัวแปรชื่อเชื้อกับชื่อยามีความสำคัญสูงสุดต่อประสิทธิภาพของโมเดล

คำสำคัญ: การประเมินคุณภาพข้อมูล; การเตรียมข้อมูล; การเรียนรู้ของเครื่อง; ผลความไวต่อยาต้านจุลชีพ; การทำนาย S/I/R; เชื้อดื้อยา; CTGAN; Random Forest

1. บทนำ

การเพาะเชื้อและการทดสอบความไวต่อยาต้านจุลชีพเป็นข้อมูลพื้นฐานสำคัญสำหรับการรักษาผู้ป่วยติดเชื้อ การกำกับการใช้ยาต้านจุลชีพ และการเฝ้าระวังการดื้อยาในโรงพยาบาล รายงาน cumulative antimicrobial susceptibility หรือ antibiogram ถูกใช้เพื่อสรุปแนวโน้มความไวของเชื้อในระดับหน่วยบริการและช่วยสนับสนุนการเลือกยารักษาเชิงประจักษ์ โดย CLSI M39 ให้แนวทางการเก็บ วิเคราะห์ และนำเสนอข้อมูลความไวต่อยาแบบสะสมอย่างเป็นระบบเพื่อให้ข้อมูลมีความน่าเชื่อถือและใช้ประโยชน์ทางคลินิกได้ อย่างไรก็ตาม ในการใช้งานจริง ข้อมูลจุลชีววิทยาจากระบบสารสนเทศโรงพยาบาลมักมีปัญหาคุณภาพข้อมูลหลายรูปแบบ เช่น ค่าว่าง ข้อมูลซ้ำ ชื่อเชื้อและชื่อยาที่บันทึกไม่เป็นมาตรฐาน หรือใช้รูปแบบรหัสต่างกันระหว่างหน่วยงาน ปัญหาเหล่านี้ทำให้ทั้งการสร้าง antibiogram และการนำข้อมูลไปสร้างแบบจำลองการเรียนรู้ของเครื่องมีความคลาดเคลื่อนมากขึ้น ระบบอย่าง WHONET และ BacLink ถูกพัฒนาขึ้นเพื่อช่วยจัดการฐานข้อมูล microbiology และมาตรฐานการนำเข้าข้อมูลจากระบบเดิม ซึ่งสะท้อนว่าการทำมาตรฐานข้อมูลและการตรวจคุณภาพข้อมูลเป็นขั้นตอนสำคัญก่อนการวิเคราะห์ขั้นสูง

ในช่วงไม่กี่ปีที่ผ่านมา การเรียนรู้ของเครื่องถูกนำมาใช้มากขึ้นในการพยากรณ์ antimicrobial resistance และผลการทดสอบความไวต่อยา โดยงานทบทวนวรรณกรรมพบว่า โมเดลตระกูล tree-based เช่น Random Forest และ gradient-boosted trees เป็นกลุ่มวิธีที่

92 ให้ผลดีบ่อยครั้งกับข้อมูลจริงในระบบสุขภาพ เนื่องจากรองรับความสัมพันธ์ไม่เชิงเส้นและตัวแปรเชิง
93 หมวดย่อยจำนวนมากได้ดี แม้งานวิจัยด้าน AMR prediction จะเพิ่มขึ้นอย่างรวดเร็ว แต่ปัญหาสำคัญ
94 ที่ยังพบร่วมกันคือ คุณภาพข้อมูลต้นทาง ความไม่สมดุลของ class และความแตกต่างของการตีความ
95 S/I/R ระหว่างระบบ breakpoints โดยเฉพาะนิยามของตัวอักษร I ที่ใน EUCAST ปัจจุบันหมายถึง
96 “Susceptible, Increased Exposure” ไม่ใช่ความหมายเดิมแบบ intermediate อย่างกว้าง ๆ
97 ดังนั้น งานวิจัยที่ใช้ข้อมูล AST เพื่อสร้างแบบจำลองจำเป็นต้องระบุให้ชัดว่าใช้ผลลัพธ์ตามระบบการ
98 ตีความของห้องปฏิบัติการใด และต้องทำ preprocessing อย่างเป็นระบบก่อนเข้าสู่การสร้าง
99 แบบจำลอง

100 งานวิจัยนี้จึงมุ่งพัฒนากรอบการเรียนรู้ของเครื่องสำหรับทำนายผลความไวต่อยาต้านจุลชีพ
101 แบบ S/I/R จากข้อมูลจุลชีววิทยาโรงพยาบาลที่ผ่านการประเมินคุณภาพและการเตรียมข้อมูลอย่าง
102 เป็นระบบ โดยให้ความสำคัญกับกระบวนการ data quality assessment, data preprocessing,
103 handling ของรายการที่ตีความไม่ได้, การลดอคติจากผลซ้ำ และการแก้ปัญหาความไม่สมดุลของ
104 ข้อมูล เพื่อให้ได้ชุดข้อมูลที่เหมาะสมสำหรับการสร้างโมเดลและให้ผลที่ทำซ้ำได้

105

106 2. วัตถุประสงค์

- 107 1) เพื่อประเมินและปรับปรุงคุณภาพข้อมูลจุลชีววิทยาของโรงพยาบาลในมิติความครบถ้วน
108 และความสอดคล้องก่อนนำไปใช้สร้างแบบจำลอง
- 109 2) เพื่อพัฒนาระบบการเตรียมข้อมูลที่ทำให้ข้อมูลเชื่อถือ เชื่อยา สิ่งส่งตรวจ และผลความไว
110 ต่อยาอยู่ในรูปแบบมาตรฐานและพร้อมสำหรับการเรียนรู้ของเครื่อง
- 111 3) เพื่อพัฒนาและเปรียบเทียบประสิทธิภาพของโมเดลการเรียนรู้ของเครื่องหลายชนิดในการ
112 ทำนายผลความไวต่อยาต้านจุลชีพแบบ S/I/R
- 113 4) เพื่อวิเคราะห์ผลกระทบของตัวแปรด้านจุลชีววิทยาและข้อมูลบริบทผู้ป่วยต่อความแม่นยำ
114 ของโมเดล

115

116 3. งานวิจัยที่เกี่ยวข้อง

117 งานวิจัยที่เกี่ยวข้องกับการศึกษานี้สามารถแบ่งได้เป็น 4 ด้านหลัก ได้แก่ (1) ระบบเฝ้าระวัง
118 และรายงานความไวต่อยาต้านจุลชีพ (2) การทำมาตรฐานและบูรณาการข้อมูลจุลชีววิทยา (3) การ
119 ประยุกต์ใช้ machine learning เพื่อทำนายผลความไวต่อยา และ (4) ช่องว่างของงานเดิมที่เกี่ยวข้อง
120 กับคุณภาพข้อมูล ความไม่สมดุลของข้อมูล และการใช้งานจริงในระบบโรงพยาบาล

121

122 ในด้านระบบเฝ้าระวังและรายงานความไวต่อยาต้านจุลชีพ CLSI M39 เป็นแนวทางสำคัญ
123 สำหรับการเก็บ วิเคราะห์ และนำเสนอข้อมูล cumulative antimicrobial susceptibility test
124 data เพื่อสนับสนุนการตัดสินใจทางคลินิกและ antimicrobial stewardship ขณะเดียวกัน องค์การ
125 อนามัยโลกได้พัฒนา Global Antimicrobial Resistance and Use Surveillance System
126 (GLASS) เพื่อกำหนดแนวทางมาตรฐานในการรวบรวม วิเคราะห์ และแบ่งปันข้อมูล AMR
127 ระดับประเทศและระดับโลก สำหรับบริบทประเทศไทย ศูนย์เฝ้าระวังเชื้อดื้อยาต้านจุลชีพแห่งชาติได้
128 รวบรวมและเผยแพร่ข้อมูล antibiogram ทั้งในรูปแบบรายงานประจำปีและระบบรายงานแยกตาม
129 เขตบริการสุขภาพ ซึ่งสะท้อนให้เห็นว่าข้อมูลผลทดสอบความไวต่อยามีบทบาทสำคัญโดยตรงต่อการ
130 เฝ้าระวังเชื้อดื้อยาและการใช้ยาปฏิชีวนะอย่างเหมาะสมในระบบสุขภาพไทย (Clinical and
131 Laboratory Standards Institute [CLSI], 2022; World Health Organization [WHO], 2023;
132 ศูนย์เฝ้าระวังเชื้อดื้อยาต้านจุลชีพแห่งชาติ [NARST], 2567, 2568).

133 ในด้านการทำมาตรฐานและบูรณาการข้อมูลจุลชีววิทยา งานหลายชิ้นชี้ให้เห็นว่าปัญหา
134 สำคัญของข้อมูลจากโรงพยาบาลไม่ได้อยู่ที่การมีข้อมูลน้อย แต่เกิดจากความแตกต่างของรูปแบบการ
135 บันทึก การใช้รหัสที่ไม่สม่ำเสมอ และการกระจายตัวของข้อมูลอยู่ในหลายระบบ Stelling, Kulldorff
136 และ O'Brien อธิบายว่า WHONET และ BacLink ถูกพัฒนาขึ้นเพื่อรองรับการ capture,
137 conversion, processing และ analysis ของข้อมูลจุลชีววิทยาจากระบบเดิม โดยเฉพาะการ
138 แลกเปลี่ยนข้อมูลในรูปแบบมาตรฐานเพื่อใช้ต่อในงาน surveillance และการกำหนดแนวทางรักษา
139 ในบริบทไทย Aramrat และ Boonma ได้พัฒนากระบวนการ ETL และการแสดงผล bacterial
140 profile และ antibiotic susceptibility profile จากข้อมูลโรงพยาบาลจริง โดยเน้นการทำความเข้าใจ
141 สะอาดข้อมูล การประเมินคุณภาพข้อมูล และการลดอคติจากข้อมูลที่ยังไม่พร้อมใช้งาน ซึ่งสอดคล้อง
142 กับแนวคิดของงานวิจัยนี้ที่ให้ความสำคัญกับ data preprocessing ก่อนเข้าสู่ขั้นตอน machine
143 learning (Aramrat & Boonma, 2023; Stelling et al., 2007)

144 ในด้านการประยุกต์ใช้ machine learning เพื่อทำนายผลความไวต่อยา งานทบทวนของ
145 Anahtar, Yang และ Kanjilal เสนอว่าการประยุกต์ ML กับปัญหา AMR ครอบคลุมทั้งการพยากรณ์
146 resistance phenotypes การทำความเข้าใจกลไกของยา และการพัฒนา clinical decision
147 support สำหรับ antimicrobial stewardship ต่อมา Corbin และคณะ ได้แสดงให้เห็นว่า
148 “personalized antibiograms” ซึ่งใช้ข้อมูลจาก electronic health records สามารถทำนาย
149 antibiotic susceptibility results และสนับสนุนการเลือกยาที่แคบลงโดยยังคง coverage ที่
150 ใกล้เคียงหรือดีกว่าการสั่งยาจริงของแพทย์ ขณะที่ Goto และคณะ เสนอ multitask machine
151 learning framework สำหรับพยากรณ์ resistance profile หลาย antimicrobial classes พร้อม
152 กันจากข้อมูล structured EHR และสร้าง individualized resistance probabilities ในรูปแบบที่

153 ใกล้เคียง antibiogram เชิงบุคคล งานเหล่านี้สะท้อนว่าการใช้ข้อมูลคลินิกจริงร่วมกับข้อมูลจุล
154 ชีววิทยาสามารถนำไปสู่แบบจำลองที่สนับสนุนการตัดสินใจเชิงประจักษ์ได้จริง ไม่ได้จำกัดอยู่เพียงการ
155 วิเคราะห์แบบ aggregate antibiogram เท่านั้น (Anahtar et al., 2021; Corbin et al., 2022;
156 Goto et al., 2026).

157 อย่างไรก็ตาม งานทบทวนวรรณกรรมล่าสุดยังชี้ให้เห็นว่าความท้าทายหลักของงาน ML ด้าน
158 AMR prediction ไม่ได้อยู่ที่การเลือกโมเดลเพียงอย่างเดียว แต่รวมถึงคุณภาพข้อมูล ความไม่เป็น
159 เนื้อเดียวกันของการประมวลผลข้อมูล ความไม่สมดุลของ class และข้อจำกัดในการนำผลไปใช้จริงใน
160 คลินิก Sakagianni และคณะ สรุปว่า machine learning มีศักยภาพสูงในการเป็นเครื่องมือเสริม
161 antibiotic stewardship แต่ประสิทธิภาพของโมเดลขึ้นอยู่กับปริมาณและคุณภาพของข้อมูลอย่าง
162 มาก ขณะที่ Ardila, González-Arroyave และ Tobón จาก systematic review ใน real-world
163 healthcare settings รายงานว่า gradient-boosted decision trees, Random Forest และ
164 XGBoost เป็นกลุ่มโมเดลที่ให้ผลดีที่สุดบ่อยครั้ง แต่ยังมีข้อจำกัดสำคัญ เช่น retrospective design,
165 nonstandard data processing และการขาด external validation ดังนั้น ช่องว่างสำคัญของ
166 วรรณกรรมจึงอยู่ที่การเชื่อมกระบวนการ data quality assessment และ data preprocessing ที่
167 เป็นระบบเข้ากับการสร้างแบบจำลองทำนายผล S/I/R จากข้อมูลโรงพยาบาลจริง ซึ่งเป็นจุดที่งานวิจัย
168 นี้มุ่งเน้นโดยตรง (Ardila et al., 2025; Sakagianni et al., 2023).

169

170 4. ระเบียบวิธีวิจัย

171 4.1 รูปแบบการศึกษาและแหล่งข้อมูล ข้อมูลที่ใช้ในการวิจัยมาจากฐานข้อมูลของ
172 โรงพยาบาล ประกอบด้วยข้อมูลผู้ป่วยในและข้อมูลผลเพาะเชื้อ/ผลความไวต่อยาจากผู้ป่วยในและ
173 ผู้ป่วยนอก โดยตัวแปรที่เกี่ยวข้องกับการวิเคราะห์ประกอบด้วยข้อมูลเชื้อ ชื่อยา ชนิดส่งส่งตรวจ ผล
174 ความไวต่อยา และข้อมูลบริบทผู้ป่วย เช่น เพศ อายุ และหอผู้ป่วย ข้อมูลจากหลายแหล่งถูกนำมารวม
175 ในขั้นตอนเตรียมข้อมูลก่อนสร้างแบบจำลอง

176 4.2 จริยธรรมการวิจัย งานวิจัยนี้ได้รับการพิจารณาและรับรองโดยคณะกรรมการจริยธรรม
177 การวิจัยในมนุษย์ของ[ชื่อมหาวิทยาลัย/โรงพยาบาล] เลขที่รับรอง [เลขที่โครงการ] การศึกษานี้เป็น
178 การวิจัยเชิงย้อนหลังโดยใช้ข้อมูลจุลชีววิทยาและข้อมูลเวชระเบียนของโรงพยาบาลที่มีอยู่เดิม ไม่มี
179 การติดต่อหรือแทรกแซงต่อผู้ป่วยโดยตรง และข้อมูลทั้งหมดถูกทำให้ไม่สามารถระบุตัวตนได้ก่อนการ
180 วิเคราะห์ คณะกรรมการจริยธรรมฯ ได้อนุมัติให้ยกเว้นการขอความยินยอมจากผู้ป่วยเป็นรายบุคคล
181 เนื่องจากการวิจัยมีความเสี่ยงต่ำและไม่ส่งผลกระทบต่อสิทธิหรือสวัสดิภาพของผู้ป่วย

182 4.3 การประเมินคุณภาพข้อมูล งานวิจัยนี้ประเมินคุณภาพข้อมูลใน 2 มิติหลัก คือ ความ
183 ครบถ้วน และ ความสอดคล้อง เนื่องจากทั้งสองมิติส่งผลโดยตรงต่อความพร้อมของข้อมูลสำหรับ

184 การเรียนรู้ของเครื่อง ให้ D เป็นชุดข้อมูลทั้งหมดที่มีจำนวนระเบียบเท่ากับ N และให้ x_{ij} แทนค่าของตัว
 185 แปรที่ j ในระเบียบที่ i

186 อัตราความครบถ้วนของตัวแปรที่ j นิยามได้เป็น

$$188 \quad \text{Completeness}_j = \frac{\sum_{i=1}^N 1(x_{ij} \neq \emptyset)}{N} \times 100$$

187 และอัตราความสอดคล้องของตัวแปรที่ j เมื่อเทียบกับเซตค่ามาตรฐาน S_j นิยามได้เป็น

$$190 \quad \text{Consistency}_j = \frac{\sum_{i=1}^N 1(x_{ij} \in S_j)}{N} \times 100$$

189 โดย $1(\cdot)$ คือ indicator function

191 **4.4 การเตรียมข้อมูล** การเตรียมข้อมูลออกแบบให้รองรับข้อมูล microbiology ที่มาจาก
 192 หลายแหล่งและมีการตั้งชื่อไม่สม่ำเสมอ โดยประกอบด้วย 5 ขั้นตอนหลัก

193 **4.4.1 การทำมาตรฐานข้อมูล** ให้ x_i เป็นคำดิบของข้อมูล เช่น ชื่อเชื้อ ชื่อยา หรือชนิดสิ่งส่ง
 194 ตรวจ และให้ $D = \{d_1, d_2, \dots, d_K\}$ เป็นชุดค่ามาตรฐาน การ mapping คำดิบไปยังค่ามาตรฐานนิยามได้
 195 เป็น

$$197 \quad z_i = \begin{cases} d_k, & \text{if } x_i \text{ matches dictionary term } d_k \\ r(x_i), & \text{if } x_i \text{ matches regex rule } r \\ d_k^*, & \text{if } \max_{k \in \{1, \dots, K\}} \text{Sim}(x_i, d_k) \geq \tau \\ \text{REVIEW}, & \text{otherwise} \end{cases}$$

196 โดย

$$200 \quad k^* = \arg \max_{k \in \{1, \dots, K\}} \text{Sim}(x_i, d_k)$$

198 เมื่อ $\text{Sim}(x_i, d_k)$ คือค่าความคล้ายคลึงระหว่างข้อมูลดิบกับค่ามาตรฐาน และ τ คือค่าขีดตัดสำหรับ
 199 fuzzy matching

201 **4.4.2 การตรวจสอบ intrinsic resistance** ให้ o_i เป็นเชื้อที่ผ่านการทำมาตรฐาน, a_i เป็นยา
 202 ที่ผ่านการทำมาตรฐาน, y_i เป็นผลความไวต่อยาดิบ และ $R_{\text{intrinsic}}$ เป็นเซตของคู่เชื้อ-ยาที่มี intrinsic
 203 resistance ตัวแปรตรวจสอบความขัดแย้งนิยามได้เป็น

$$205 \quad I_i = 1((o_i, a_i) \in R_{\text{intrinsic}} \wedge y_i = S)$$

204 ถ้า $I_i = 1$ ระเบียบดังกล่าวจะถูกส่งไปตรวจทานเพิ่มเติม

206 **4.4.3 การกำหนด REVIEW flag** ให้ f_i เป็นสถานะของระเบียบที่ i

$$207 \quad f_i = \begin{cases} \text{REVIEW}, & \text{if missing in critical fields} \\ \text{REVIEW}, & \text{if unmapped or fuzzy score} < \tau \\ \text{REVIEW}, & \text{if } I_i = 1 \\ \text{VALID}, & \text{otherwise} \end{cases}$$

208 จากนั้นชุดข้อมูลที่ใช้สำหรับ supervised learning นิยามได้เป็น

209
$$D_{ML} = \{ i \in D \mid f_i = \text{VALID}, y_i \in \{S, I, R\} \}$$

210 **4.4.4 การลบข้อมูลซ้ำแบบ first-isolate rule** ให้ระเบียนที่ *ไม่มี*ข้อมูลผู้ป่วย p_i , เชื้อ o_i ,
211 สิ่งส่งตรวจ s_i , และวันที่ตรวจ t_i กำหนดตัวบ่งชี้การเก็บระเบียนไว้เป็น first isolate ได้เป็น

213
$$\delta_i = 1 \left(\nexists j < i : p_j = p_i, o_j = o_i, s_j = s_i, 0 < t_i - t_j \leq 30 \right)$$

212 ดังนั้นชุดข้อมูลหลัง deduplication คือ

215
$$D_{\text{dedup}} = \{ i \in D_{ML} \mid \delta_i = 1 \}$$

214 **4.4.5 ชุดข้อมูลสุดท้ายสำหรับการสร้างโมเดล** กำหนดชุดข้อมูลสุดท้ายเป็น

217
$$D^* = \{ (x_i, y_i) \mid i \in D_{\text{dedup}}, y_i \in \{S, I, R\} \}$$

216 โดยเวกเตอร์ตัวแปรอธิบายคือ

219
$$x_i = (\text{org_clean_final}, \text{anti_name_clean}, \text{specimen_clean}, \text{sex}, \text{age}, \text{ward_admit_code})$$

218 และตัวแปรเป้าหมายคือ

220
$$y_i = \text{anti_result_clean} \in \{S, I, R\}$$

221 **4.5 การจัดการปัญหาความไม่สมดุลของข้อมูล** จากการสำรวจข้อมูลเบื้องต้นพบว่า class I
222 มีสัดส่วนน้อยมากเมื่อเทียบกับ class S และ R จึงใช้ CTGAN สร้างข้อมูลสังเคราะห์เฉพาะในชุดฝึก
223 เพื่อหลีกเลี่ยง data leakage และเพิ่มความสามารถของโมเดลในการเรียนรู้ class ที่พบได้น้อย

224 **4.6 การออกแบบการทดลอง** หลังจากผ่านกระบวนการประเมินคุณภาพข้อมูลและการ
225 เตรียมข้อมูลแล้ว ชุดข้อมูลก่อนการปรับสมดุลมีจำนวน 497,542 ระเบียน และหลังจากใช้ CTGAN
226 ปรับสมดุลข้อมูลเฉพาะในชุดฝึกแล้ว ได้ชุดข้อมูลสำหรับการสร้างแบบจำลองจำนวน 1,011,906
227 ระเบียน โดยแบ่งข้อมูลออกเป็นชุดฝึกและชุดทดสอบในสัดส่วน 80% และ 20% ตามลำดับ ส่งผลให้
228 ชุดฝึกมีจำนวน 809,524 ระเบียน และชุดทดสอบมีจำนวน 202,382 ระเบียน ในการศึกษาครั้งนี้ การ
229 ปรับสมดุลข้อมูลด้วย CTGAN ถูกใช้เฉพาะกับชุดฝึกเท่านั้น เพื่อช่วยให้แบบจำลองเรียนรู้คลาสที่มี
230 จำนวนน้อยได้ดีขึ้น โดยเฉพาะคลาส I ขณะที่ชุดทดสอบยังคงรักษาไว้ในรูปแบบข้อมูลจริง เพื่อใช้
231 สำหรับประเมินประสิทธิภาพของแบบจำลองอย่างเป็นธรรม เพื่อศึกษาความสำคัญของตัวแปร ได้
232 กำหนดการทดลอง 3 กรณี

- 233 • **กรณีที่ 1:** organism + antibiotic + specimen + sex + age + ward
234 • **กรณีที่ 2:** antibiotic + specimen + sex + age + ward
235 • **กรณีที่ 3:** specimen + sex + age + ward

236 การลดตัวแปรที่ละชุดทำให้สามารถประเมินได้ว่าตัวแปรด้านจุลชีววิทยามีผลต่อความแม่นยำ
237 ของโมเดลมากน้อยเพียงใด

238 **4.7 แบบจำลองการเรียนรู้ของเครื่อง** งานวิจัยนี้เปรียบเทียบโมเดลแบบ tree-based
 239 จำนวน 4 แบบ ได้แก่ Decision Tree, Random Forest, XGBoost และ CatBoost ซึ่งเป็นกลุ่ม
 240 โมเดลที่ถูกใช้บ่อยในงานทำนาย AMR/AST จากข้อมูลเชิงตารางและข้อมูลเชิงหมวดหมู่จำนวนมาก
 241 ให้ x_i เป็นเวกเตอร์ตัวแปรอธิบายของตัวอย่างที่ i และ $y_i \in \{S, I, R\}$ เป็นคลาสจริง ผลทำนายสุดท้ายของ
 242 ทุกโมเดลเขียนได้เป็น

$$243 \quad \hat{y}_i = \arg \max_{c \in \{S, I, R\}} \hat{p}(y=c | x_i)$$

244 **4.7.1 Decision Tree** Decision Tree ใช้เกณฑ์ impurity เพื่อเลือก split ที่ดีที่สุดในงาน
 245 นี้ใช้ Gini impurity

$$246 \quad G(t) = 1 - \sum_{c \in \{S, I, R\}} p(c|t)^2$$

247 โดยการเลือก split ที่ทำให้ impurity ลดลงมากที่สุดนิยามได้เป็น

$$248 \quad \Delta I(s, t) = I(t) - \frac{N_{t_L}}{N_t} I(t_L) - \frac{N_{t_R}}{N_t} I(t_R)$$

249 **4.7.2 Random Forest** Random Forest เป็น ensemble ของ decision trees หลาย
 250 ต้น โดยผลทำนายสุดท้ายได้จากการโหวตเสียงข้างมาก

$$251 \quad \hat{y}(x) = \text{mode} \{h_b(x)\}_{b=1}^B$$

252 หรือในรูปความน่าจะเป็นเฉลี่ยของแต่ละคลาส

$$253 \quad \hat{p}(y=c|x) = \frac{1}{B} \sum_{b=1}^B p_b(y=c|x)$$

254 **4.7.3 XGBoost** XGBoost ใช้แนวคิด gradient boosting โดยเพิ่มต้นไม้ทีละต้นเพื่อแก้
 255 residual ของรอบก่อนหน้า

$$256 \quad \hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i)$$

257 ฟังก์ชันวัตถุประสงค์เขียนได้เป็น

$$258 \quad L^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$$

259 **4.7.4 CatBoost** CatBoost เป็น gradient boosting ที่ออกแบบมาสำหรับ categorical
 260 features โดยเฉพาะ และใช้แนวคิด ordered boosting

$$262 \quad F^{(t)}(x) = F^{(t-1)}(x) + \alpha h_t(x)$$

261

263 โดย $h_t(x)$ เป็น base learner ในรอบที่ t

264 **4.8 การประเมินผล** ประสิทธิภาพของแบบจำลองถูกประเมินด้วย Accuracy, Macro
 265 Precision, Macro Recall, Macro F1-score และ Confusion Matrix โดยให้ความสำคัญกับ
 266 Macro F1-score เป็นพิเศษ เนื่องจากข้อมูลมีความไม่สมดุลระหว่างคลาส
 267 สมการ Accuracy นิยามได้เป็น

$$268 \quad \text{Accuracy} = \frac{\sum_{i=1}^n 1(\hat{y}_i = y_i)}{n}$$

269 สำหรับแต่ละคลาส c นิยาม Precision และ Recall เป็น

$$270 \quad \text{Precision}_c = \frac{TP_c}{TP_c + FP_c}$$

$$271 \quad \text{Recall}_c = \frac{TP_c}{TP_c + FN_c}$$

272 และ F1-score ของคลาส c เป็น

$$273 \quad F1_c = \frac{2 \cdot \text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c}$$

274 ส่วน Macro F1-score คำนวณจากค่าเฉลี่ยของทุกคลาส

$$275 \quad \text{Macro F1} = \frac{1}{3} \sum_{c \in \{S, I, R\}} F1_c$$

276 **5. ผลการทดลอง**

277 **5.1 ผลการประเมินและเตรียมข้อมูล**

278 ก่อนการสร้างแบบจำลอง ได้มีการรวบรวมข้อมูลเฉพาะเชื้อจากสองแหล่ง ได้แก่ ข้อมูล
 279 ผู้ป่วยใน (IPD Culture) จำนวน 1,097,459 ระเบียบ และข้อมูลผู้ป่วยนอก (OPD Culture) จำนวน
 280 215,358 ระเบียบ รวมข้อมูลดิบทั้งสิ้น 1,312,817 ระเบียบ จากนั้นดำเนินการประเมินคุณภาพข้อมูล
 281 ในมิติความครบถ้วนและความสอดคล้องของข้อมูลจุลชีววิทยาและข้อมูลบริบทผู้ป่วย โดยพิจารณาตัว
 282 แปรสำคัญ ได้แก่ ชื่อเชื้อ ชื่อยา สิ่งส่งตรวจ ผลความไวต่อยา เพศ อายุ และหอผู้ป่วย

283 หลังจากนั้น ข้อมูลถูกนำเข้าสู่กระบวนการทำมาตรฐานด้วย dictionary mapping, regular
 284 expressions และ fuzzy matching เพื่อทำความสะอาดและแปลงข้อมูลให้อยู่ในรูปแบบมาตรฐาน
 285 จากนั้นดำเนินการกรองเฉพาะระเบียบที่มีผลความไวต่อยาเป็น S, I หรือ R พบว่ามีข้อมูลที่ผ่านเกณฑ์
 286 จำนวน 643,230 ระเบียบ นอกจากนี้ยังมีระเบียบที่ไม่สามารถตีความได้น่าเชื่อถือ หรือมีความ
 287 ขัดแย้งกับ intrinsic resistance rules ซึ่งถูกกำหนดเป็น REVIEW และคัดออกจากกระบวนการ
 288 วิเคราะห์

289 เมื่อดำเนินการ deduplication โดยใช้ first-isolate rule ภายใน 30 วัน เพื่อลดอคติจาก
 290 ผลเพาะเชื้อซ้ำของผู้ป่วยรายเดิม พบว่ามีข้อมูลคงเหลือจำนวน 628,099 ระเบียบ จากนั้นได้ทำการ

merge ข้อมูลเฉพาะเชื้อกับข้อมูลบริบทผู้ป่วย (IPD_Data) ซึ่งประกอบด้วยเพศ อายุ และหอผู้ป่วย โดยใช้หมายเลข admission (AN) เป็นตัวเชื่อม ได้ชุดข้อมูลสำหรับการสร้างแบบจำลองจำนวน 528,134 ระเบียบ ซึ่งสอดคล้องกับจำนวนระเบียบที่ใช้ในการปรับสมดุลข้อมูลด้วย CTGAN ก่อนเข้าสู่กระบวนการเทรนโมเดลทั้ง 3 กรณีการทดลอง

ผลดังกล่าวแสดงให้เห็นว่า กระบวนการประเมินคุณภาพข้อมูลและการเตรียมข้อมูลมีบทบาทสำคัญในการยกระดับความพร้อมของข้อมูลจุลชีววิทยาสำหรับการเรียนรู้ของเครื่อง โดยช่วยลดปัญหาค่าขาดหาย ความไม่สอดคล้องของการบันทึก ข้อมูลที่ตีความไม่ได้ และอคติจากผลซ้ำ ก่อนเข้าสู่กระบวนการสร้างแบบจำลองทำนายผลความไวต่อยาต้านจุลชีพแบบ S/I/R

5.2 ผลการเปรียบเทียบแบบจำลอง ผลการเปรียบเทียบแบบจำลองทั้ง 4 ชนิดภายใต้ 3 กรณีการทดลอง แสดงดังตารางที่ 1 โดยรายงาน Accuracy, Macro Precision, Macro Recall และ Macro F1-score เพื่อสะท้อนประสิทธิภาพของแบบจำลองในทุกคลาสอย่างสมดุล โดยเฉพาะในกรณีที่ข้อมูลมีความไม่สมดุลระหว่าง S, I และ R

ตารางที่ 1 ผลการทำนายผลความไวต่อยาต้านจุลชีพแบบ S/I/R ในทั้ง 3 กรณี

กรณี	Features	โมเดล	Accuracy	Macro Precision	Macro Recall	Macro F1
กรณีที่ 1	Org, Anti, Specimen, Sex, Age and Ward	Decision Tree	62.78%	0.630	0.627	0.630
		Random Forest	75.05%	0.750	0.750	0.750
		XGBoost	69.38%	0.693	0.693	0.693
		CatBoost	66.86%	0.667	0.667	0.667
กรณีที่ 2	Anti, Specimen, Sex, Age and Ward	Decision Tree	55.02%	0.550	0.550	0.547
		Random Forest	66.33%	0.663	0.663	0.660
		XGBoost	62.01%	0.617	0.620	0.617
		CatBoost	59.50%	0.593	0.593	0.593
กรณีที่ 3	Specimen, Sex, Age and Ward	Decision Tree	50.31%	0.517	0.500	0.503
		Random Forest	62.36%	0.630	0.623	0.623
		XGBoost	54.35%	0.547	0.543	0.543
		CatBoost	51.30%	0.517	0.510	0.513

305 จากตารางที่ 1 พบว่า Random Forest ให้ผลดีที่สุดในทุกกรณี ทั้งในด้าน Accuracy,
306 Macro Precision, Macro Recall และ Macro F1-score โดยกรณีที่ 1 ซึ่งใช้ตัวแปรครบทั้งหมดให้
307 ผลดีที่สุด ด้วย Accuracy 75.05%, Macro Precision 0.75, Macro Recall 0.75 และ Macro F1-
308 score 0.75 รองลงมาคือ XGBoost ซึ่งให้ผลอยู่ในระดับรองลงมาอย่างสม่ำเสมอ ส่วน CatBoost
309 ให้ผลใกล้เคียงกับ XGBoost แต่ต่ำกว่าเล็กน้อย ขณะที่ Decision Tree ให้ผลต่ำสุดในทุกกรณี

310 เมื่อพิจารณาตามกรณีการทดลอง พบว่าเมื่อถอดตัวแปรชื่อเชื้อออกในกรณีที่ 2 ประสิทธิภาพ
311 ของทุกโมเดลลดลงอย่างชัดเจน และเมื่อถอดทั้งชื่อเชื้อและชื่อยาออกในกรณีที่ 3 ค่าประเมินทุกตัว
312 ลดลงต่อเนื่อง สะท้อนว่าตัวแปรด้านจุลชีววิทยา โดยเฉพาะชื่อเชื้อและชื่อยา มีบทบาทสำคัญต่อการ
313 ทำนายผล S/I/R

314 **5.3 ผลของการลดตัวแปร** เพื่อประเมินความสำคัญของตัวแปรต่อการทำนายผล S/I/R ได้มี
315 การเปรียบเทียบผลของโมเดลที่ดีที่สุดในแต่ละกรณี คือ Random Forest ดังแสดงในตารางที่ 2

316

317 **ตารางที่ 2** เปรียบเทียบผลของ Random Forest เมื่อมีการลดตัวแปร

กรณี	Features	Accuracy	Macro Precision	Macro Recall	Macro F1	ผลต่าง Accuracy
กรณีที่ 1	Org, Anti, Specimen, Sex, Age and Ward	75.05%	0.75	0.75	0.75	—
กรณีที่ 2	Anti, Specimen, Sex, Age and Ward	66.33%	0.66	0.66	0.66	-8.72%
กรณีที่ 3	Specimen, Sex, Age and Ward	62.36%	0.63	0.62	0.62	-3.97%

318 จากตารางที่ 2 พบว่า ชื่อเชื้อ (org_clean_final) เป็นตัวแปรที่มีอิทธิพลต่อประสิทธิภาพของ
319 โมเดลมากที่สุด โดยเมื่อตัดออกจากกรณีที่ 1 ทำให้ Accuracy ลดลง 8.72% จาก 75.05% เหลือ
320 66.33% พร้อมกับที่ค่า Macro Precision, Macro Recall และ Macro F1-score ลดลงจาก 0.75
321 เหลือ 0.66 ทั้งหมด นอกจากนี้ เมื่อถอดตัวแปร ชื่อยา (anti_name_clean) ออกจากกรณีที่ 2 ต่อไป
322 อีกหนึ่งขั้น ความแม่นยำลดลงเพิ่มเติมอีก 3.97% เหลือ 62.36% และค่า macro metrics ก็ลดลง
323 ตามลำดับเช่นกัน ผลดังกล่าวยืนยันว่าข้อมูลทางจุลชีววิทยา โดยเฉพาะชื่อเชื้อและชื่อยา มีผลโดยตรง
324 ต่อความสามารถของโมเดลในการแยกความแตกต่างของผล S/I/R

325 **5.4 ผลการจำแนกเชิงรายคลาสของโมเดลที่ดีที่สุด** เพื่อให้เห็นพฤติกรรมของโมเดลใน
 326 ระดับรายคลาส ได้มีการวิเคราะห์ผลของ Random Forest ซึ่งเป็นโมเดลที่ดีที่สุดในทุกกรณี ดังแสดง
 327 ในตารางที่ 3
 328 **ตารางที่ 3** ผลการจำแนกเชิงรายคลาสของ Random Forest

กรณี	Class	Precision	Recall	F1-score
กรณีที่ 1	I	0.78	0.77	0.77
	R	0.74	0.73	0.74
	S	0.73	0.75	0.74
กรณีที่ 2	I	0.74	0.72	0.73
	R	0.61	0.62	0.61
	S	0.64	0.65	0.64
กรณีที่ 3	I	0.74	0.64	0.69
	R	0.56	0.50	0.53
	S	0.59	0.73	0.65

329 เมื่อพิจารณาเชิงรายคลาสของโมเดลที่ดีที่สุด พบว่า Random Forest สามารถทำนาย class
 330 I ได้ดีที่สุดในทุกกรณีที่ 1 โดยมี Precision 0.78, Recall 0.77 และ F1-score 0.77 แสดงให้เห็นว่าเมื่อ
 331 ข้อมูลเชื้อและยาครบถ้วน โมเดลสามารถแยกความแตกต่างของคลาสที่มีความซับซ้อนสูงได้ดี
 332 นอกจากนี้ class R และ S ในกรณีที่ 1 ยังมีค่า F1-score อยู่ที่ 0.74 และ 0.74 ตามลำดับ สะท้อน
 333 ถึงความสมดุลของโมเดลในทั้ง 3 คลาส

334 อย่างไรก็ตาม เมื่อจำนวนตัวแปรลดลง ประสิทธิภาพของคลาส R และ S ลดลงตามลำดับ
 335 โดยเฉพาะในกรณีที่ 3 ซึ่งไม่มีข้อมูลเชื้อเชื้อและชื่อยา class R มี Precision 0.56, Recall 0.50 และ
 336 F1-score 0.53 ขณะที่ class S แม้มี Recall สูงถึง 0.73 แต่ Precision ลดลงเหลือ 0.59 สะท้อนว่า
 337 การไม่มีข้อมูลทางจุลชีววิทยาโดยตรงทำให้โมเดลสูญเสียความสามารถในการทำนายบางคลาอย่าง
 338 สมดุล และมีแนวโน้มสับสนระหว่างคลาสมากขึ้น

339 **5.5 ผลของการจัดการข้อมูลไม่สมดุลด้วย CTGAN** ก่อนการปรับสมดุลข้อมูล พบว่า class
 340 I มีสัดส่วนต่ำกว่าคลาส S และ R อย่างชัดเจน โดย class S มีจำนวน 337,302 ระเบียบ คิดเป็น
 341 67.80% class R มีจำนวน 149,112 ระเบียบ คิดเป็น 29.97% และ class I มีจำนวนเพียง 11,128
 342 ระเบียบ คิดเป็น 2.24% ของข้อมูลทั้งหมด 497,542 ระเบียบ ความไม่สมดุลดังกล่าวส่งผลให้
 343 แบบจำลองไม่สามารถเรียนรู้ class I ได้อย่างมีประสิทธิภาพ โดยก่อนการปรับสมดุล พบว่าทุกโมเดล
 344 มี recall ของ class I เท่ากับ 0.00

หลังจากใช้ CTGAN (Conditional Tabular Generative Adversarial Network) สร้างข้อมูล synthetic เพิ่มเติมเฉพาะในชุดฝึก พบว่าความสามารถของโมเดลในการทำนาย class I ดีขึ้นอย่างชัดเจน โดยเฉพาะในโมเดล Random Forest, XGBoost และ CatBoost ซึ่งสามารถรักษาค่า Precision และ Recall ของ class I ไว้ในระดับค่อนข้างสูงได้ในทุกกรณี สะท้อนว่า CTGAN ช่วยลดผลกระทบของ class imbalance และทำให้การประเมินผลในระดับ multiclass มีความสมดุลมากขึ้น

ตารางที่ 4 การกระจายตัวของคลาสก่อนและหลังการปรับสมดุลข้อมูลด้วย CTGAN

Class	ก่อน CTGAN (n)	ก่อนCTGAN (%)	หลัง CTGAN (n)	หลัง CTGAN (%)
S	337,302	67.80	337,302	33.33
R	149,112	29.97	337,302	33.33
I	11,128	2.24	337,302	33.33
รวม	497,542	100.00	1,011,906	100.00

หมายเหตุ: CTGAN สร้างข้อมูล synthetic เพิ่ม 514,364 ระเบียบ โดย class I เพิ่มจาก 11,128 เป็น 337,302 ระเบียบ และ class R เพิ่มจาก 149,112 เป็น 337,302 ระเบียบ เพื่อให้ทุก class มีสัดส่วนเท่ากัน (33.33%) ก่อนนำเข้าสู่กระบวนการเทรนโมเดล ทั้งนี้ CTGAN ถูก Train เพียงครั้งเดียวและใช้ร่วมกันทั้ง 3 กรณีการทดลอง

5.6 สรุปผลเชิงแบบจำลอง โดยรวม Random Forest เป็นโมเดลที่เหมาะสมที่สุด กับชุดข้อมูลของงานวิจัยนี้ เนื่องจากให้ Accuracy สูงสุดและมีค่า Macro Precision, Macro Recall และ Macro F1-score สูงสุดในทุกกรณี นอกจากนี้ยังคงรักษาผลการจำแนกเชิงรายคลาสได้ดีกว่าโมเดลอื่น แม้ในสถานการณ์ที่มีการลดจำนวนตัวแปรลง

XGBoost ให้ผลรองลงมาและความเสถียรในระดับดี ขณะที่ CatBoost แม้มีข้อได้เปรียบในการรองรับ categorical features โดยตรง แต่ผลรวมยังต่ำกว่า Random Forest เล็กน้อย ส่วน Decision Tree มีจุดเด่นด้านความตีความง่าย แต่ให้ประสิทธิภาพต่ำกว่าโมเดล ensemble และ boosting อย่างชัดเจน โดยเฉพาะเมื่อข้อมูลทางจุลชีววิทยาถูกลดทอนลง

โดยสรุป ผลการทดลองยืนยันว่า ข้อมูลจุลชีววิทยาที่ผ่านการประเมินคุณภาพและการเตรียมข้อมูลอย่างเป็นระบบ สามารถนำมาใช้สร้างแบบจำลองการเรียนรู้ของเครื่องเพื่อทำนายผลความไวต่อยาต้านจุลชีพแบบ S/I/R ได้อย่างมีประสิทธิภาพ และตัวแปรเชื้อเชื้อกับเชื้อยามีความสำคัญสูงสุดต่อความสำเร็จของการทำนาย

370

371 6. อภิปรายผล

372 ผลการศึกษานี้แสดงให้เห็นว่า การพัฒนาแบบจำลองสำหรับทำนายผลความไวต่อยาต้านจุล
373 ชีพแบบ S/I/R ไม่ควรพิจารณาเฉพาะการเลือกอัลกอริทึม แต่ต้องเริ่มจากการประเมินคุณภาพข้อมูล
374 และการเตรียมข้อมูลอย่างเป็นระบบก่อน ข้อมูลจุลชีววิทยาที่ผ่านการทำมาตรฐานชื่อเชื้อ ชื่อยา และ
375 สิ่งส่งตรวจ การตรวจสอบความสอดคล้องของผล AST การคัดกรองรายการที่ไม่สามารถตีความได้
376 และการลบผลซ้ำตาม first-isolate rule ช่วยลด noise จากระบบสารสนเทศเดิมและทำให้ข้อมูลมี
377 ความพร้อมมากขึ้นสำหรับ supervised learning ส่งผลให้แบบจำลองสามารถเรียนรู้ความสัมพันธ์
378 ระหว่างปัจจัยทางจุลชีววิทยากับผล S/I/R ได้อย่างมีประสิทธิภาพ

379 เมื่อพิจารณาผลการทดลองในทุกกรณี พบว่า Random Forest ให้ผลดีที่สุดอย่างสม่ำเสมอ
380 โดยในกรณีที่ใช้ตัวแปรครบทั้งหมด โมเดลให้ Accuracy 75.05%, Macro Precision 0.75, Macro
381 Recall 0.75 และ Macro F1-score 0.75 ขณะที่เมื่อถอดตัวแปรชื่อเชื้อออก ค่าประเมินลดลงเป็น
382 66.33%, 0.66, 0.66 และ 0.66 ตามลำดับ และเมื่อถอดทั้งชื่อเชื้อและชื่อยาออก ค่าประเมินลดลง
383 ต่อเนื่องเป็น 62.36%, 0.63, 0.62 และ 0.62 ตามลำดับ ผลดังกล่าวสะท้อนอย่างชัดเจนว่าตัวแปร
384 ด้านจุลชีววิทยา โดยเฉพาะ ชื่อเชื้อและชื่อยา มีความสำคัญต่อการทำนายผล S/I/R มากที่สุด

385 เมื่อพิจารณาเชิงรายละเอียดของโมเดลที่ดีที่สุด พบว่า Random Forest สามารถทำนาย class
386 I ได้ดีที่สุดในการที่ใช้ข้อมูลครบ โดยมี Precision 0.78, Recall 0.77 และ F1-score 0.77 ขณะที่
387 class R และ S มี F1-score เท่ากับ 0.74 และ 0.74 ตามลำดับ แสดงว่าโมเดลไม่เพียงให้ Accuracy
388 สูง แต่ยังรักษาสสมดุลของ Precision และ Recall ในทุกคลาสได้ดี อย่างไรก็ตาม เมื่อจำนวนตัวแปร
389 ลดลง โดยเฉพาะเมื่อไม่มีข้อมูลชื่อเชื้อและชื่อยา ประสิทธิภาพของ class R และ S ลดลงชัดเจน
390 สะท้อนว่าโมเดลสูญเสียข้อมูลสำคัญที่ใช้แยกรูปแบบความไวและความดื้อยาในระดับคลินิก

391 ผลลัพธ์ของงานวิจัยนี้สอดคล้องกับแนวคิดของ Corbin et al. (2022) ซึ่งแสดงให้เห็นว่า
392 machine learning ที่ใช้ข้อมูลจากเวชระเบียนอิเล็กทรอนิกส์สามารถสร้าง “personalized
393 antibiograms” เพื่อพยากรณ์ antibiotic susceptibility patterns และช่วยสนับสนุนการเลือกยา
394 ที่เหมาะสมโดยยังคงประสิทธิภาพในการครอบคลุมเชื้อได้ดี ในทำนองเดียวกัน งานของ Goto et al.
395 (2026) เสนอ multitask machine learning framework สำหรับการพยากรณ์ individualized
396 resistance profiles จาก structured EHR data และชี้ให้เห็นว่าการใช้ข้อมูลเชิงบริบทของผู้ป่วย
397 ร่วมกับข้อมูลจุลชีววิทยาสามารถเพิ่มความแม่นยำของการพยากรณ์เชิงคลินิกได้ งานวิจัยนี้มีความ
398 สอดคล้องกับทั้งสองงานในแง่ที่ยืนยันว่า ข้อมูลทางคลินิกและจุลชีววิทยาที่เตรียมอย่างเป็นระบบ
399 สามารถใช้สร้างแบบจำลองทำนาย susceptibility ได้จริง

อย่างไรก็ตาม งานวิจัยนี้มีความแตกต่างจากงานของ Corbin และ Goto ในสองประเด็นสำคัญ ประเด็นแรก งานนี้เน้นการพยากรณ์ผล S/I/R โดยตรงในระดับ multiclass classification มากกว่าการสร้างความเป็นของ susceptibility profile ราย antimicrobial class หรือการสนับสนุนการเลือกยาบุคคล ประเด็นที่สอง งานนี้ให้ความสำคัญกับ data quality-driven preprocessing อย่างชัดเจน ตั้งแต่การประเมิน completeness และ consistency การทำมาตรฐานข้อมูล การกำหนด REVIEW และการลอคคิตจากผลซ้ำ ซึ่งเป็นขั้นตอนที่มีบทบาทสำคัญต่อความน่าเชื่อถือของโมเดล แต่ในวรรณกรรมมักได้รับการอธิบายไว้ไม่ละเอียดเท่าขั้นตอนการสร้างแบบจำลอง

แม้ผลการทดลองจะแสดงให้เห็นว่า Random Forest เป็นโมเดลที่เหมาะสมที่สุดกับชุดข้อมูลนี้ แต่ยังมีข้อจำกัดที่ควรพิจารณา ประการแรก ประสิทธิภาพของโมเดลยังขึ้นกับคุณภาพของ dictionary mapping และกฎ intrinsic resistance หาก rule base ยังไม่ครอบคลุมเพียงพอ อาจทำให้บางระเบียบถูกกำหนดเป็น REVIEW มากเกินความจำเป็น และลดปริมาณข้อมูลที่ใช้ฝึกแบบจำลอง ประการที่สอง แม้งานวิจัยนี้ใช้ CTGAN เพื่อจัดการ class imbalance ในชุดฝึก โดยผลการเปรียบเทียบก่อนและหลังการปรับสมดุลแสดงให้เห็นว่า class I เพิ่มขึ้นจาก 2.24% เป็น 33.33% ส่งผลให้โมเดลสามารถเรียนรู้ class ที่มีจำนวนน้อยได้ดีขึ้น อย่างไรก็ตาม ข้อมูล synthetic ที่สร้างจาก CTGAN ยังไม่ใช่ข้อมูลผู้ป่วยจริง จึงควรมีการทดสอบ external validation กับข้อมูลจากช่วงเวลาอื่นหรือโรงพยาบาลอื่นในอนาคต ประการที่สาม ผลลัพธ์ S/I/R ยังขึ้นกับ breakpoint system ที่ห้องปฏิบัติการใช้ จึงควรระบุระบบการตีความให้ชัดและควรมีการทดสอบ external validation กับข้อมูลจากช่วงเวลาอื่นหรือโรงพยาบาลอื่นในอนาคต เพื่อประเมินความสามารถในการ generalize ของโมเดล

โดยสรุป การอภิปรายผลของงานนี้ชี้ให้เห็นว่า ความสำเร็จของการทำนาย S/I/R ไม่ได้ขึ้นกับโมเดลเพียงอย่างเดียว แต่เกิดจากการผสมกันระหว่าง คุณภาพข้อมูล, การเตรียมข้อมูลอย่างเป็นระบบ, และ การเลือกโมเดลที่เหมาะสมกับข้อมูลเชิงตารางและตัวแปรเชิงหมวดหมู่จำนวนมาก ซึ่งเป็นจุดที่ทำให้งานนี้มีคุณค่าเชิงประยุกต์ต่อการพัฒนาระบบสนับสนุนการตัดสินใจทางคลินิกในบริบทโรงพยาบาล

425

426 7. สรุปผลการวิจัย

งานวิจัยนี้ได้นำเสนอกรอบการเรียนรู้ของเครื่องสำหรับทำนายผลความไวต่อยาต้านจุลชีพแบบ S/I/R จากข้อมูลจุลชีววิทยาโรงพยาบาลที่ผ่านการประเมินคุณภาพและการเตรียมข้อมูลอย่างเป็นระบบ โดยกระบวนการสำคัญประกอบด้วยการตรวจสอบความครบถ้วนและความสอดคล้องของข้อมูล การทำมาตรฐานชื่อเชื้อ ชื่อยา และสิ่งส่งตรวจ การคัดกรองรายการที่ไม่สามารถตีความได้ การ

431 ตรวจสอบ intrinsic resistance และการลบผลซ้ำด้วย first-isolate rule ภายใน 30 วัน ก่อนนำ
432 ข้อมูลเข้าสู่ขั้นตอนการสร้างแบบจำลอง

433 ผลการทดลองแสดงให้เห็นว่า Random Forest เป็นโมเดลที่ให้ผลดีที่สุดในทุกกรณี โดยเมื่อ
434 ใช้ตัวแปรครบทั้งหมด โมเดลให้ Accuracy 75.05%, Macro Precision 0.75, Macro Recall 0.75
435 และ Macro F1-score 0.75 ขณะที่เมื่อถอดตัวแปรชื่อเชื้อออก ค่าประเมินลดลงเป็น 66.33%, 0.66,
436 0.66 และ 0.66 ตามลำดับ และเมื่อถอดทั้งชื่อเชื้อและชื่อยาออก ค่าประเมินลดลงต่อเนื่องเป็น
437 62.36%, 0.63, 0.62 และ 0.62 ตามลำดับ ผลเชิงรายคลาสยังแสดงให้เห็นว่าโมเดลสามารถทำนาย
438 class I ได้ดีที่สุดเมื่อข้อมูลจุลชีววิทยาครบถ้วน และประสิทธิภาพของ class R และ S ลดลงเมื่อไม่มี
439 ข้อมูลชื่อเชื้อและชื่อยา

440 เมื่อพิจารณาร่วมกับวรรณกรรมที่เกี่ยวข้อง ผลงานชิ้นนี้สนับสนุนข้อค้นพบจากงานด้าน
441 personalized antibiograms และ individualized resistance prediction ที่ชี้ว่า machine
442 learning สามารถนำข้อมูลคลินิกและข้อมูลจุลชีววิทยามาใช้พยากรณ์ผล susceptibility ได้จริง และ
443 มีศักยภาพในการต่อยอดไปสู่ clinical decision support ได้ จุดเด่นของงานวิจัยนี้คือการเน้น data
444 quality-driven preprocessing อย่างเป็นรูปธรรม ซึ่งช่วยให้ข้อมูลจากระบบโรงพยาบาลมีความ
445 พร้อมสำหรับการเรียนรู้ของเครื่องและเพิ่มความน่าเชื่อถือของผลการพยากรณ์

446 โดยสรุป ข้อมูลจุลชีววิทยาที่ผ่านการควบคุมคุณภาพและการเตรียมข้อมูลอย่างเป็นระบบ
447 สามารถนำมาใช้พัฒนาแบบจำลองการเรียนรู้ของเครื่องเพื่อทำนายผลความไวต่อยาต้านจุลชีพแบบ
448 S/I/R ได้อย่างมีประสิทธิภาพ และตัวแปรชื่อเชื้อกับชื่อยามีความสำคัญสูงสุดต่อความสำเร็จของ
449 โมเดล งานวิจัยนี้จึงเป็นพื้นฐานสำคัญสำหรับการพัฒนาระบบสนับสนุนการตัดสินใจทางคลินิกและ
450 การเฝ้าระวัง AMR ในอนาคต

451

452 8. เอกสารอ้างอิง

453 Anahtar, M. N., Yang, J. H., & Kanjilal, S. (2021). Applications of machine learning to the
454 problem of antimicrobial resistance: An emerging model for translational
455 research. *Journal of Clinical Microbiology*, 59(7), e01260-20.

456 Aramrat, C., & Boonma, P. (2023). Development of data processing and visualization
457 for bacterial and antibiotic susceptibility profile. *Data Science and Engineering*
458 *Record*, 4(1).

459 Ardila, C. M., González-Arroyave, D., & Tobón, S. (2025). Machine learning for predicting
460 antimicrobial resistance in critical and high-priority pathogens: A systematic
461 review considering antimicrobial susceptibility tests in real-world healthcare

462 settings. PLOS ONE, 20(2), e0319460.

463 Clinical and Laboratory Standards Institute. (2022). M39: Analysis and presentation of
464 cumulative antimicrobial susceptibility test data (5th ed.). Clinical and
465 Laboratory Standards Institute.

466 Corbin, C. K., Sung, L., Chattopadhyay, A., Noshad, M., Chang, A., Deresinski, S.,
467 Baiocchi, M., & Chen, J. H. (2022). Personalized antibiograms for machine learning
468 driven antibiotic selection. Communications Medicine, 2, Article 38.

469 Goto, M., Bandyopadhyay, A., Shi, Q., Wang, Y., Perencevich, E. N., Hernandez,
470 D., & Street, W. N. (2026). Personalized antibiogram: A novel multitask machine
471 learning framework for simultaneous prediction of antimicrobial resistance
472 profile with enhanced detection of carbapenem resistance in
473 Enterobacteriaceae. Clinical Infectious Diseases. Advance online publication.

474 NARST. (2567). รายงานประจำปีศูนย์เฝ้าระวังเชื้อดื้อยาต้านจุลชีพ พ.ศ. 2567. ศูนย์เฝ้าระวังเชื้อดื้อ
475 ยาด้านจุลชีพแห่งชาติ, กรมวิทยาศาสตร์การแพทย์.

476 NARST. (2568). Antibiograms แยกตามเขตบริการสุขภาพ. ศูนย์เฝ้าระวังเชื้อดื้อยาต้านจุลชีพ
477 แห่งชาติ, กรมวิทยาศาสตร์การแพทย์.

478 Sakagianni, A., Koufopoulou, C., Feretzakis, G., Kalles, D., Verykios, V. S., Myrianthefs,
479 P., & Fildis, G. (2023). Using machine learning to predict antimicrobial resistance: A
480 literature review. Antibiotics, 12(3), 452.

481 Stelling, J., O'Brien, T. F., & others. (2007). WHONET and BacLink: Software tools for
482 laboratory-based surveillance of infectious diseases and antimicrobial
483 resistance. In Proceedings of the International Society for Disease Surveillance.

484 World Health Organization. (2022). Global antimicrobial resistance and use
485 surveillance system (GLASS) report: 2022. World Health Organization.

486 World Health Organization. (2023). Global Antimicrobial Resistance and Use
487 Surveillance System (GLASS). World Health Organization.

488 WHONET. (2026). WHONET microbiology laboratory database software. WHO
489 Collaborating Centre for Surveillance of Antimicrobial Resistance.